Taller 1

Maria Fernanda Gordillo Robles - 122117

Karen Yulieth Montaña Sanchez - 123757

Adrian David Sierra Chavarro - 122228

Facultad de Ingeniería Industrial

Universidad ECCI

Sistemas Avanzados de Producción

01 de Marzo del 2026

Fase 1 Estadística Descriptiva y Análisis Exploratorio

Variable	Media (Mean)	Mediana (Median)	Desv. Estándar (Std)	Mínimo (Min)	Máximo (Max)	Asimetría (Skewness)	Curtosis (Kurtosis)
TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Radio	23.2640	22.90	14.846809	0.0	49.6	0.094175	-1.260401

Tabla [1]: Esta tabla muestra las medidas de tendencia central y dispersión para la variable independientes y la variable Sales dependientes.

Análisis de Distribución y Atípicos

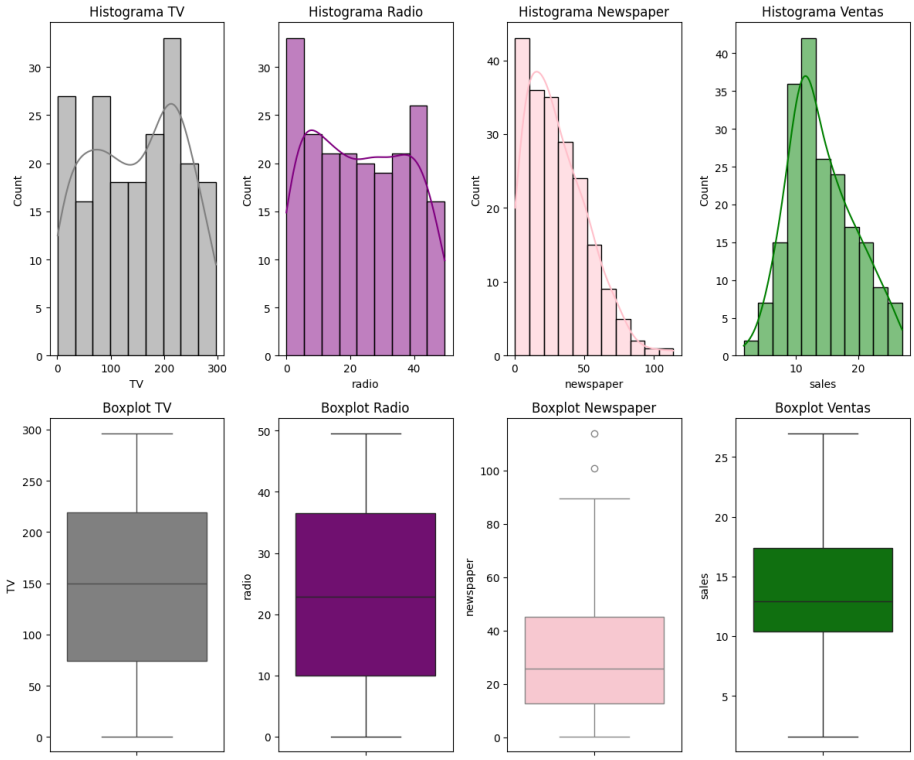

Figura [1]: En la sección superior se ilustran los histogramas de las variables TV, Radio, Newspaper y Ventas, mientras que en la sección inferior se presentan sus respectivos diagramas de caja (boxplot), facilitando la visualización de la distribución, dispersión y posibles valores atípicos.

El análisis de la asimetría muestra que la mayoría de las variables presentan distribuciones aproximadamente simétricas, dado que sus coeficientes de skewness se encuentran cercanos a cero. En particular, las variables con valores de -0.0698 y 0.0942 evidencian una distribución prácticamente equilibrada alrededor de la media.

Por su parte, la variable con asimetría de 0.4076 presenta una ligera inclinación hacia la derecha, aunque dentro de un rango considerado bajo. Finalmente, la variable con coeficiente de 0.8947 muestra una asimetría positiva moderada, indicando una mayor concentración de datos en valores bajos y la presencia de algunos valores altos que extienden la cola derecha de la distribución.

En general, no se observan niveles extremos de asimetría que comprometan significativamente la normalidad de los datos.

Por otra parte, el análisis descriptivo sugiere que la mayoría de las variables presentan distribuciones relativamente simétricas y sin evidencia fuerte de valores atípicos. Sin embargo, la variable Newspaper muestra una asimetría positiva moderada y una curtosis positiva, lo que indica la posible presencia de valores altos que se alejan de la masa principal de los datos.

Estas observaciones atípicas podrían influir en la estimación de una línea de regresión, ya que pueden alterar la pendiente y desplazar la recta hacia los valores extremos, afectando la precisión y estabilidad del modelo.

Evaluación de asociación.

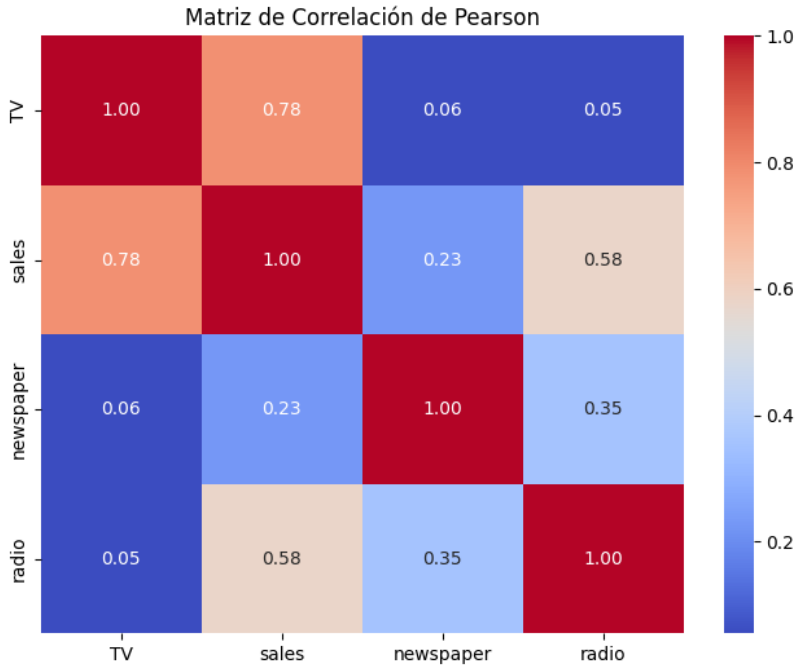

Figura [2]: Matriz de correlación de Pearson entre las variables analizadas.

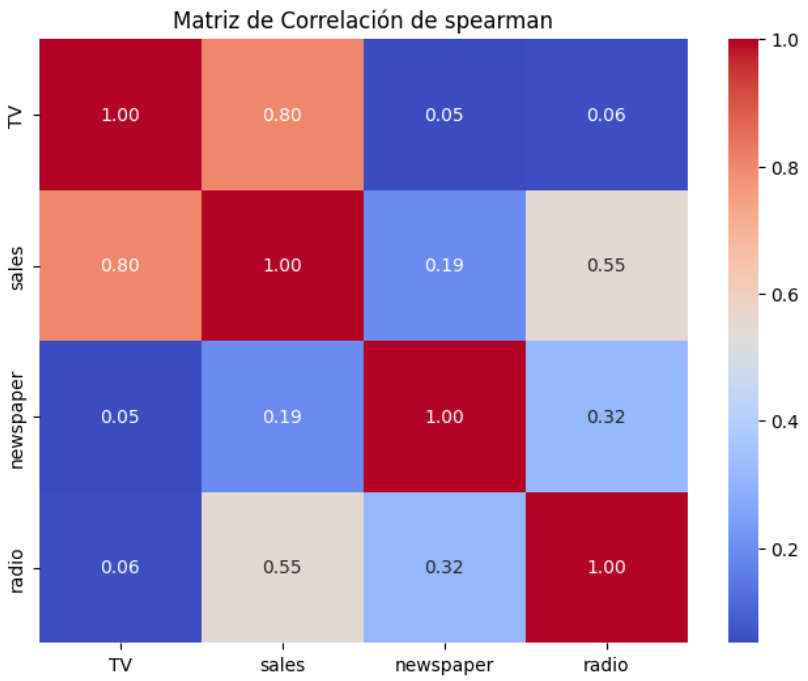

Figura [3]: Matriz de correlación de Spearman que evalúa la relación monotónica entre las variables analizadas.

El análisis de correlación muestra que la inversión en TV es la variable más fuertemente asociada con las ventas, presentando una relación positiva alta tanto en Pearson ($r = 0.78$) como en Spearman ($\rho = 0.80$). Esto indica que un mayor gasto en televisión se relaciona consistentemente con mayores niveles de ventas.

La inversión en radio presenta una relación positiva moderada con las ventas ($r = 0.58$; $\rho = 0.55$), lo que sugiere que este medio también contribuye al incremento en las ventas, aunque con menor intensidad que la televisión.

Por su parte, newspaper evidencia una asociación positiva débil con las ventas ($r = 0.23$; $\rho = 0.19$), lo que indica una relación limitada entre este tipo de inversión publicitaria y el desempeño en ventas.

En cuanto a la relación entre los distintos medios, las correlaciones entre TV, radio y newspaper son bajas o muy débiles, lo que sugiere que las inversiones en cada canal tienden a comportarse de manera relativamente independiente.

Finalmente, la similitud entre los coeficientes de Pearson y Spearman indica que las relaciones identificadas son estables, aproximadamente lineales y no están fuertemente influenciadas por valores atípicos.

- ¿Qué significa un coeficiente cercano a 1 o −1 en el contexto de la inversión publicitaria y el retorno en ventas?

  Coeficiente cercano a 1: Indica una relación positiva muy fuerte; cuando aumenta la inversión en un medio, también aumentan las ventas de forma consistente.

  Coeficiente menor a 1: Indica que una relación negativa es muy fuerte; cuando una variable sube, la otra baja.

- ¿Cómo se interpreta un valor de correlación cercano a 0?

  Un coeficiente cercano a 0 indica que no existe relación lineal ni monótona fuerte entre las variables.

  Por ejemplo:

  TV – Newspaper: 0.06

  Sales – Newspaper: 0.23 (Pearson) y 0.19 (Spearman)

  Esto sugiere que aumentar el gasto en periódico no predice de manera clara un aumento en ventas. Puede haber relación, pero es débil o no lineal.

- Compare ambos coeficientes (Pearson y Spearman). ¿Sugieren estos resultados que las relaciones son estrictamente lineales? Justifique su respuesta basándose en la forma de la nube de puntos observada.

  Aunque los coeficientes de Pearson y Spearman sean altos, eso no obliga a que la relación sea una línea recta perfecta.

  Lo podemos evidenciar en los datos obtenidos:

  TV vs Sales: relación creciente clara; puntos alineados con tendencia lineal.

  Radio vs Sales: relación moderada, algo lineal pero con dispersión.

  Newspaper vs Sales: nube dispersa, sin dirección clara → relación muy débil.

Fase 2: Regresión Lineal y Diagnóstico

Interpretación de parametros.

Tenemos los siguientes datos:

Intercepto (beta_0): 2.9389

Pendiente (beta_1): 0.0458

Pendiente (beta_2): 0.1885

Pendiente (beta_3): -0.0010

- Interprete el intercepto $\hat{\beta}_0$ indicando si tiene sentido conceptual que sea diferente de cero.

El intercepto representa el valor esperado de las ventas cuando todas las variables explicativas son cero:

$\beta 0$=ventas esperadas si no se invierte en TV, ni radio, ni newspaper

Eso quiere decir que, si la empresa no invierte absolutamente nada en publicidad, el modelo predice unas ventas promedio de 2.9389 unidades.

Este si tiene un sentido conceptual, ya que, algunas empresas todavía no cuenten con esquemas sólidos de publicidad en ellas, por este motivo no cuentan con gastos de promoción de sus productos.

- Interprete los coeficientes $\hat{\beta}_1$, $\hat{\beta}_2$ y $\hat{\beta}_3$ bajo el concepto de variación de la media de Y cuando hay un incremento unitario de la covariable, manteniendo la otra constante (ceteris paribus).

  $\hat{\beta}_1$: Si la inversión en TV aumenta en una unidad, manteniendo constante la inversión en Radio y Newspaper, la media de las ventas aumenta en 0.0458 unidades.

  $\hat{\beta}_2$: Si la inversión en Radio aumenta en una unidad, manteniendo constante la inversión en TV y Newspaper, la media de las ventas aumenta en 0.1885 unidades.

  $\hat{\beta}_3$: Si la inversión en Newspaper aumenta en una unidad, manteniendo constante la inversión en TV y Radio, la media de las ventas disminuye en 0.0010 unidades.

Análisis de bondad de ajuste: Para este análisis contamos con las siguientes gráficas:

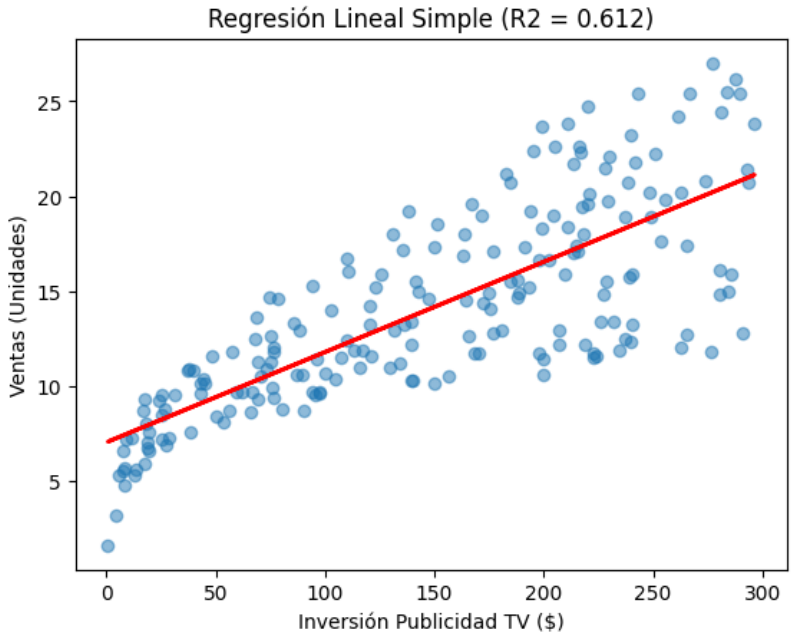

Figura [4]: Modelo de regresión para publicidad TV

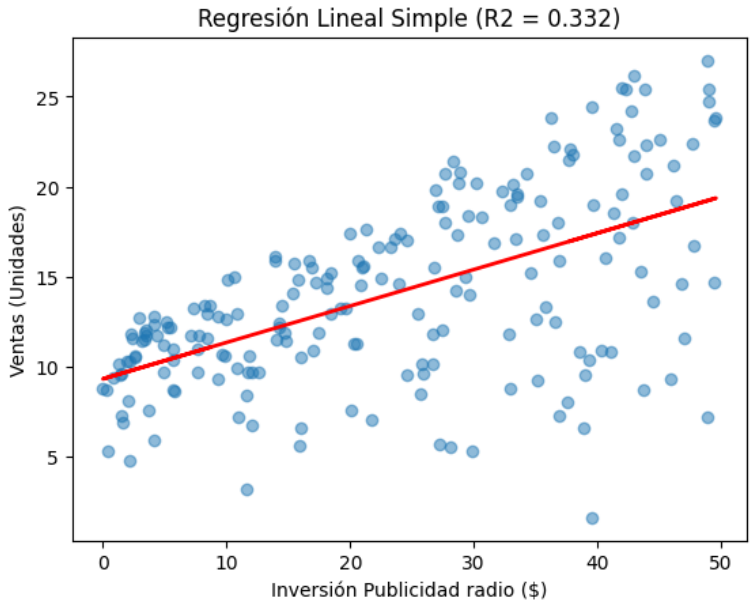

Figura [5]: Modelo de regresión para publicidad en radio

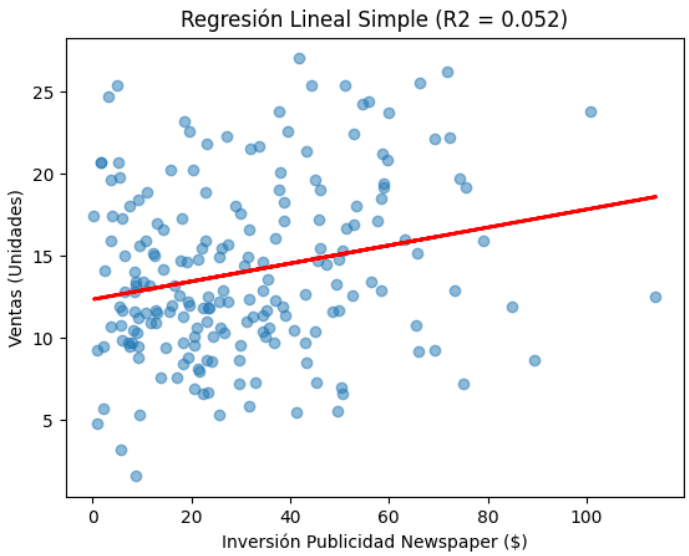

Figura [5]: Modelo de regresión para publicidad en Newspaper

Además, contamos con los siguientes datos:

--- Coeficientes del Modelo ---

Intercepto (beta_0): 2.9389

Coeficiente TV (beta_1): 0.0458

Coeficiente Radio (beta_2): 0.1885

Coeficiente Newspaper (beta_3): -0.0010

--- Bondad de Ajuste ---

R-cuadrado (R2): 0.8972

Los indicadores de ajuste muestran que el modelo de regresión se desempeña muy bien. El valor de $R^2 = 0.8972$ indica que aproximadamente el 89.72% de la variabilidad total en las ventas puede atribuirse a los cambios en las inversiones realizadas en TV, radio y periódico. En otras palabras, estas tres formas de publicidad explican casi toda la variación observada en las ventas, lo que refleja un modelo con una gran capacidad para describir el comportamiento de la variable dependiente.

Estimación Matricial

Se tienen las siguientes matrices:

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Figura [6]: Matrices a trabajar.

- Calcule la matriz transpuesta X′.

  $X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$

- Calcule el producto X′X y su respectiva matriz inversa (X′X) −1

  $X'X = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$

  $(X'X)^{-1} = \begin{pmatrix} 1{,}1 & -0{,}3 \\ -0{,}3 & 0{,}1 \end{pmatrix}$

- Calcule el producto X′Y.

  $X'Y = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$

- Obtenga el vector de parámetros βˆ y escriba la ecuación de la recta estimada ˆy = βˆ

  0+βˆ 1x.

  $(X'X)^{-1} = \begin{pmatrix} 1{,}1 & -0{,}3 \\ -0{,}3 & 0{,}1 \end{pmatrix}, X'Y = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$

  $\hat{B} = \begin{pmatrix} 1{,}1 & -0{,}3 \\ -0{,}3 & 0{,}1 \end{pmatrix} \begin{pmatrix} 28 \\ 101 \end{pmatrix}$

  B0 = 1,1 (28) + (-0,3) (101) = 30,8 - 30,3 = 0,5

  B1 = -0,3 (28) + 0,1 (101) = -8,4 + 10,1 = 1,7

  Vector final: βˆ = $\begin{pmatrix} 0{,}5 \\ 1{,}7 \end{pmatrix}$

Recta estimada: $\hat{y} = 0{,}5 + 1{,}7\,x$

Fase 3: Árboles de Decisión y Comparación de Modelos

1. **Entrenamiento del Modelo:**

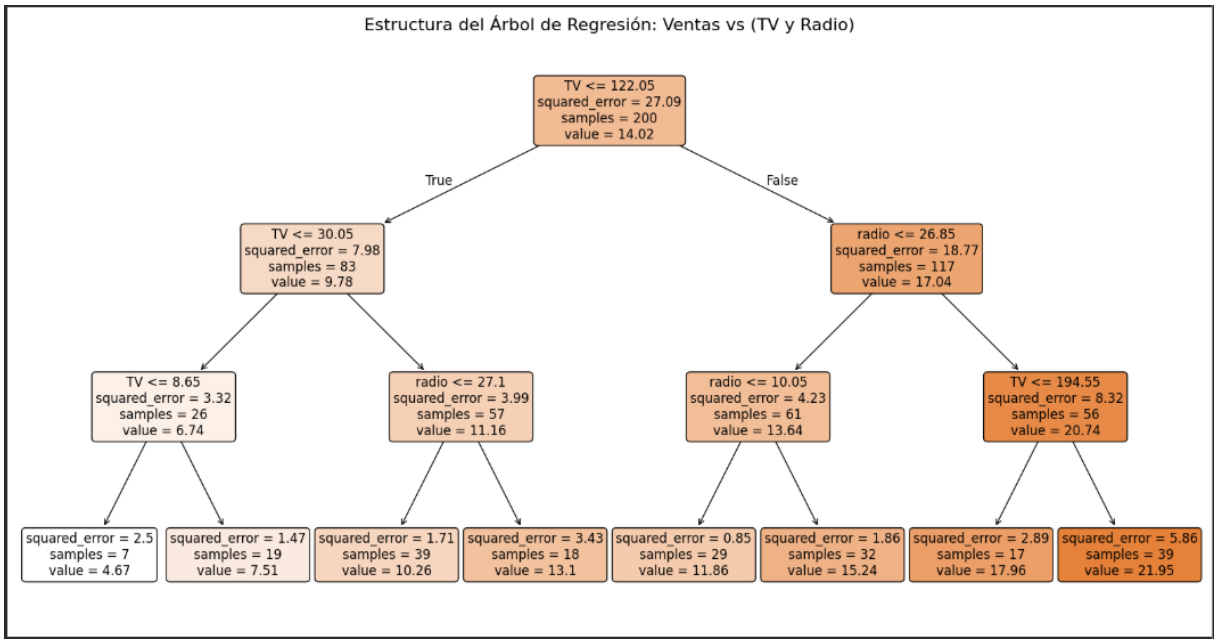

Las particiones del árbol se realizan bajo el criterio de minimización del error cuadrático (squared_error). En cada nodo, el algoritmo evalúa distintos puntos de corte sobre las variables TV y Radio y selecciona aquel que produce subconjuntos más homogéneos en términos de ventas. A medida que el árbol se profundiza, el error disminuye progresivamente, lo que indica que las predicciones dentro de cada hoja son más precisas.

Adicionalmente, se observa que la variable TV aparece como el primer criterio de división en el nodo raíz, lo que indica que es el predictor con mayor capacidad explicativa sobre las ventas. Posteriormente, la variable Radio interviene como factor de ajuste en subsegmentos específicos, refinando la predicción dentro de cada grupo. Esto sugiere que la inversión en televisión

tiene un impacto estructural más fuerte en las ventas, mientras que la publicidad en radio cumple un rol complementario. Desde una perspectiva analítica, la reducción progresiva del error en los nodos hoja evidencia que el modelo logra segmentar adecuadamente el espacio de predictores; sin embargo, un árbol demasiado profundo podría generar sobreajuste, por lo que es recomendable controlar la profundidad o validar el desempeño con datos de prueba.

2. **Cálculo Manual de Incertidumbre (Clasificación)**:

Datos

Mercados (4):

TV Alta → Ventas Altas

TV Alta → Ventas Altas

TV Baja → Ventas Bajas

TV Baja → Ventas Altas

Conteo total (nodo padre S):

Altas: 3

Bajas: 1

1- **Entropía del Nodo Padre**
Proporciones:

$$\mathrm{p(Altas)} = 3/4 = \mathbf{0.75}$$
$$\mathrm{p(Bajas)} = 1/4 = \mathbf{0.25}$$

Entropía Padre:

$$\mathrm{H(S)} = -[0.75\, log_2(0.75) + 0.25\, log_2(0.25)] \approx \mathbf{0.811}$$

2- **Índice de Gini del Nodo Padre**

$$\mathrm{Gini(S)} = 1 - (0.75^2 + 0.25^2) = 1 - (0.5625 + 0.0625) = \mathbf{0.375}$$

3- **Ganancia de información al partir por Inversión TV (Alta/Baja)**

Subconjunto TV = Alta (2 mercados)

Resultados: Altas, Altas

Altas: 2/2 = 1
Bajas: 0/2 = 0

Entropía = 0 (puro)

Subconjunto TV = Baja (2 mercados)

Resultados: Bajas, Altas

Altas: 1/2 = 0.5
Bajas: 1/2 = 0.5

Entropía = 1

Entropía ponderada después de la partición

Peso Alta: 2/4 = 0.5 → 0.5 * 0 = 0
Peso Baja: 2/4 = 0.5 → 0.5 * 1 = 0.5

Entropía post-partición = 0.5

Ganancia de información

IG = Entropía padre − Entropía post
IG = 0.811 − 0.5 = 0.311

Ganancia de información ≈ 0.311 bits

La partición por la variable Inversión TV demuestra una capacidad efectiva de reducción de incertidumbre en el nodo padre. Inicialmente, el conjunto total presentaba una entropía de aproximadamente 0.811, lo que indica un nivel moderado de desorden en la clasificación entre “Altas” y “Bajas”. Tras dividir los datos según el nivel de inversión en TV, uno de los subconjuntos (TV Alta) se vuelve completamente puro, eliminando la incertidumbre en ese grupo, mientras que el subconjunto TV Baja mantiene un nivel máximo de incertidumbre al estar perfectamente balanceado. La reducción total de entropía (ganancia de información ≈ 0.311) confirma que la variable Inversión TV aporta capacidad discriminatoria relevante para separar las clases.

Desde una perspectiva metodológica, este resultado ilustra el principio central de los árboles de decisión: seleccionar particiones que maximicen la homogeneidad interna de los nodos hijos. Aunque el conjunto de datos es pequeño y simplificado, el ejercicio evidencia cómo una variable explicativa puede reducir significativamente la incertidumbre incluso sin lograr una separación perfecta en todos los subconjuntos. En términos estratégicos, esto sugiere que la inversión en televisión tiene un efecto estructural sobre el desempeño en ventas, aunque no es el único factor determinante, ya que aún persiste heterogeneidad cuando la inversión es baja. En consecuencia, la variable es informativa, pero no completamente determinística, lo que refleja la naturaleza probabilística de los modelos de clasificación.

Importancia o Peso de los Predictores identificados en el Random Forest.

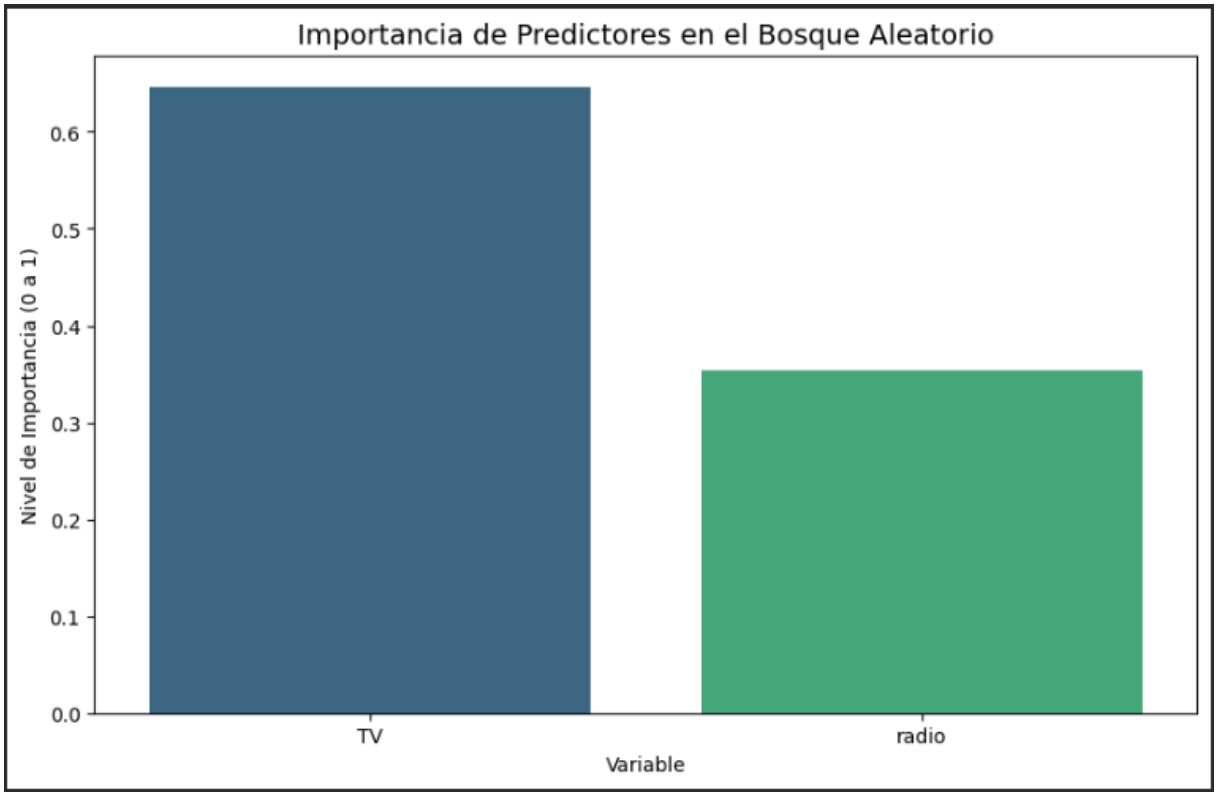

El gráfico de importancia de variables obtenido a partir del modelo de Bosque Aleatorio muestra que la inversión en TV presenta un peso aproximado del 65 %, mientras que la inversión en radio explica cerca del 35 % de la capacidad predictiva del modelo. Esto indica que, dentro del esquema no paramétrico, la publicidad en televisión es el factor dominante en la reducción del error de predicción de ventas.

Desde el punto de vista metodológico, la importancia en Random Forest se calcula con base en la reducción acumulada del error cuadrático a lo largo de todos los árboles del ensamble. Por lo tanto, que TV tenga mayor peso significa que, en promedio, las particiones basadas en esta variable generan subconjuntos más homogéneos y mejoran más la precisión del modelo que las particiones basadas en radio.

Este resultado es consistente con el análisis previo de correlación y regresión lineal, donde TV mostró la asociación más fuerte con Sales. La convergencia entre modelos paramétricos (regresión) y no paramétricos (árboles y bosque aleatorio) refuerza la robustez del hallazgo: la televisión es el principal motor explicativo del comportamiento de las ventas en este dataset.

En términos estratégicos, la empresa debería priorizar la inversión en TV como eje central de su estrategia publicitaria, utilizando la radio como complemento táctico. Sin embargo, el hecho de que radio conserve un 35 % de importancia indica que no es irrelevante y contribuye de manera significativa al desempeño global del modelo.

Conclusiones

El análisis realizado permitió evaluar de manera integral la relación entre la inversión publicitaria y el desempeño en ventas, combinando herramientas de estadística descriptiva, regresión lineal y modelos no paramétricos como los árboles de decisión. Los resultados obtenidos evidencian que la inversión en televisión constituye el principal predictor de ventas, mostrando una correlación fuerte y positiva, así como el mayor impacto estructural dentro del modelo de regresión múltiple. La inversión en radio presenta un efecto complementario moderado, mientras que la inversión en newspaper no demuestra una contribución significativa al explicar la variabilidad en las ventas.

Desde la perspectiva del modelamiento paramétrico, la regresión lineal múltiple mostró un alto nivel de ajuste ($R^2 \approx 0.8972$), lo que indica que cerca del 90 % de la variabilidad en las ventas puede explicarse por las inversiones en publicidad. Este resultado sugiere que el comportamiento de las ventas sigue una relación predominantemente lineal con los presupuestos publicitarios, lo cual hace que la regresión lineal sea un modelo altamente interpretable y adecuado para la toma de decisiones estratégicas, especialmente cuando se requiere claridad en la magnitud del impacto marginal de cada medio (ceteris paribus).

Por otro lado, el árbol de regresión permitió capturar la estructura de segmentación del espacio de los predictores, identificando que la variable TV es el primer criterio de partición, lo que confirma su relevancia explicativa. Este enfoque no paramétrico ofrece ventajas cuando existen posibles no linealidades o efectos de interacción entre variables, aunque puede ser más sensible al sobreajuste si no se controla adecuadamente la profundidad del árbol. En este caso particular, dado que las relaciones observadas son aproximadamente lineales y estables, el modelo de regresión lineal resulta más robusto e interpretable para fines de negocio.

En términos estratégicos, los resultados sugieren que la empresa debería priorizar la inversión en televisión como principal motor de crecimiento en ventas, utilizando la radio como complemento táctico. La evidencia empírica no respalda una asignación significativa de recursos al canal newspaper bajo las condiciones actuales del mercado. En consecuencia, para este conjunto de datos y bajo los supuestos evaluados, la regresión lineal múltiple emerge como el modelo más adecuado, al ofrecer un equilibrio óptimo entre capacidad predictiva, estabilidad y facilidad de interpretación para la toma de decisiones gerenciales.